

Sistemas basados en agentes y modelos de lenguaje (LLMs) para la automatización de workflows en bioinformática: arquitecturas, aplicaciones y desafíos

Jose Camacho*

06 Mayo 2026

Resumen

Los modelos de lenguaje de gran escala (LLMs) han abierto nuevas posibilidades para automatizar tareas complejas en bioinformática, pero su naturaleza probabilística limita su uso directo en workflows científicos que requieren trazabilidad, precisión y reproducibilidad. Esta mini-review analiza 15 estudios sobre sistemas basados en agentes aplicados a transcriptómica, *single-cell omics*, modelado farmacocinético, descubrimiento terapéutico, visualización científica y generación automatizada de protocolos. La evidencia muestra una transición desde enfoques basados en *prompting* hacia arquitecturas agénticas capaces de planificar tareas, invocar herramientas externas, ejecutar código, autocorregirse y coordinar agentes especializados. Los principales hallazgos señalan que la orquestación jerárquica, el *grounding*, la observabilidad y los protocolos de interoperabilidad como el Model Context Protocol (MCP) son elementos centrales para escalar estos sistemas. Persisten desafíos relacionados con alucinaciones, coste computacional, propagación de errores, ausencia de benchmarks estandarizados y gobernanza científica. En conjunto, los sistemas agénticos representan un cambio de paradigma: no solo automatizan tareas repetitivas, sino que pueden funcionar como copilotos científicos capaces de ampliar el acceso a workflows bioinformáticos complejos bajo supervisión humana. **Palabras clave:** modelos de lenguaje de gran escala, sistemas agénticos, bioinformática, automatización, workflows, reproducibilidad, gobernanza

*Máster en Bioinformática, Universidad Nebrija.

Contents

1	Introducción	3
2	Metodología de búsqueda	3
2.1	Pregunta de investigación	3
2.2	Bases de datos y estrategia de búsqueda	4
2.3	Criterios de inclusión y exclusión	4
2.4	Selección de estudios	5
3	Síntesis temática	6
3.1	Arquitecturas agénticas y patrones de orquestación	8
3.2	Automatización de pipelines bioinformáticos específicos	10
3.3	Reproducibilidad, benchmarking y evaluación comparativa	12
3.4	Limitaciones técnicas y consideraciones de gobernanza	13
4	Discusión	15
4.1	Hallazgos principales	15
4.2	Limitaciones	15
4.3	Vacíos en la literatura	17
5	Conclusiones	17
5.1	El cambio de paradigma: de LLMs a sistemas agénticos	17
5.2	La verificabilidad como requisito científico	17
5.3	Perspectivas futuras y estandarización	18

1 Introducción

La bioinformática contemporánea depende de workflows compuestos por múltiples herramientas, formatos de archivo y decisiones analíticas que rara vez siguen una trayectoria completamente lineal. Aunque los pipelines tradicionales han permitido estandarizar tareas como alineamiento, cuantificación, anotación o modelado, su ejecución sigue exigiendo intervención humana para adaptar parámetros, resolver errores, encadenar software heterogéneo y reinterpretar resultados intermedios. Esta fricción se vuelve más evidente en contextos como la transcriptómica, las ómicas de célula única o la farmacometría, donde la complejidad técnica crece al mismo ritmo que el volumen de datos.

En ese escenario, los modelos de lenguaje de gran escala (LLMs) han comenzado a desempeñar un papel distinto al de asistentes conversacionales genéricos. Cuando se integran en sistemas capaces de planificar, invocar herramientas, ejecutar código y corregir errores a partir de la retroalimentación del entorno, los LLMs pasan de ser interfaces de *prompting* a componentes de arquitecturas agénticas orientadas a la automatización científica [1, 2]. Esta evolución ha favorecido agentes que operan sobre notebooks, APIs, bases de datos, software bioinformático y servicios web.

Sin embargo, el interés creciente por estos sistemas no ha venido acompañado de un marco sintético claro para describir cómo están siendo diseñados, evaluados y limitados dentro del dominio bioinformático. La literatura reciente incluye agentes recursivos, sistemas multi-agente, asistentes con *grounding* y plataformas con observabilidad, pero persisten preguntas sobre reproducibilidad, coste computacional, trazabilidad, control humano e interoperabilidad. El campo avanza rápido en prototipos y demostraciones, pero todavía carece de una visión ordenada de sus arquitecturas dominantes y de sus condiciones de validez científica.

Esta mini-review examina 15 estudios publicados en 2025 y 2026 sobre el uso de LLMs y sistemas basados en agentes para la automatización de workflows en bioinformática. La Sección 2 describe la estrategia de búsqueda y los criterios de selección; la Sección 3 organiza la evidencia en cuatro ejes temáticos; la Sección 4 discute los hallazgos, limitaciones y vacíos de la literatura; y la Sección 5 presenta las conclusiones y perspectivas futuras del área.

2 Metodología de búsqueda

2.1 Pregunta de investigación

Se formuló una pregunta de investigación basada en el marco PICO:

¿Qué tan efectivos son los sistemas basados en Large Language Models (LLMs) y

agentes en comparación con workflows tradicionales para la automatización de pipelines bioinformáticos?

Table 1. Marco PICO de la pregunta de investigación.

Componente	Descripción
P: Población	Pipelines bioinformáticos, incluyendo análisis de RNA-seq, genómica y transcriptómica.
I: Intervención	Sistemas basados en Large Language Models (LLMs) y agentes.
C: Comparación	Workflows tradicionales, tales como scripts manuales y pipelines estáticos.
O: Resultado	Nivel de automatización, eficiencia, reproducibilidad y control del flujo de trabajo.

2.2 Bases de datos y estrategia de búsqueda

La búsqueda se realizó en PubMed, complementada con repositorios académicos y plataformas de preprints, abarcando publicaciones entre 2020 y 2026. La estrategia se ejecutó el 5 de mayo de 2026 mediante la siguiente ecuación:

```
("large language models"[TIAB] OR LLM OR "AI agents")
AND ("bioinformatics" OR "RNA-seq" OR "genomics")
AND ("workflow" OR "pipeline" OR "automation" OR "agent" OR
"orchestration")
```

Se seleccionaron estudios enfocados en la orquestación de flujos de trabajo y sistemas agénticos, integrando adicionalmente documentación técnica sobre marcos de trabajo como LangChain y fundamentos de agentes para sustentar el análisis arquitectónico.

2.3 Criterios de inclusión y exclusión

Criterios de inclusión

- Estudios que describieran arquitecturas explícitas basadas en agentes, incluyendo planificación, uso de herramientas externas o sistemas multi-agente.
- Aplicaciones directas en bioinformática, tales como genómica, transcriptómica, proteómica o diseño automatizado de protocolos.
- Artículos que analizaran desafíos técnicos asociados al uso de LLMs y agentes, incluyendo alucinaciones, reproducibilidad, coste computacional o control de ejecución.
- Publicaciones que propusieran benchmarks, métricas o estrategias de evaluación para sistemas basados en agentes.

Criterios de exclusión

- Estudios enfocados exclusivamente en aplicaciones clínicas o diagnóstico por imagen sin relación con workflows bioinformáticos.
- Trabajos que utilizaran LLMs únicamente mediante prompting simple, sin capacidades de planificación, uso de herramientas o ejecución autónoma.
- Artículos centrados en aplicaciones médicas no relacionadas con bioinformática computacional, incluyendo encuestas de satisfacción de pacientes, medicina tradicional china o estudios clínicos sin componente de automatización de workflows.
- Publicaciones sin descripción metodológica clara o sin relación directa con infraestructura computacional basada en agentes.

2.4 Selección de estudios

La búsqueda inicial recuperó 40 artículos de PubMed. El cribado de títulos, resúmenes y conclusiones excluyó estudios sobre aplicaciones clínicas, *prompting* simple o medicina no computacional. Tras aplicar los criterios de inclusión, se seleccionaron 15 artículos para la síntesis cualitativa (Figure 1).

Para complementar el análisis de las arquitecturas implementadas en dichos artículos, se integró de forma dirigida la documentación técnica de LangChain, la cual sirvió como marco de referencia para fundamentar los componentes de diseño de agentes, memoria y uso de herramientas discutidos en esta revisión [3–5].




Figure 1. Diagrama de flujo PRISMA del proceso de selección de estudios.

3 Síntesis temática

Los 15 estudios seleccionados fueron analizados y categorizados en cuatro ejes temáticos que abordan desde el diseño estructural hasta la validación científica de los sistemas. La Section 3.1 examina las arquitecturas agénticas; la Section 3.2 analiza la automatización de pipelines específicos, incluyendo genómica, scRNA-seq y farmacometría; la Section 3.3 evalúa las estrategias de reproducibilidad y benchmarking; y finalmente, la Section 3.4 discute las limitaciones técnicas y los marcos de gobernanza.

La Table 2 sintetiza las características operativas, aplicaciones clave y hallazgos principales de la evidencia analizada, sirviendo como base para la discusión técnica subsiguiente.

1. Arquitecturas agénticas y patrones de orquestación.
2. Automatización de pipelines bioinformáticos específicos.
3. Reproducibilidad, benchmarking y evaluación comparativa.
4. Limitaciones técnicas, supervisión humana y gobernanza.

Table 2. Tabla de extracción de datos de los estudios incluidos.

Autor, año	Enfoque	Aplicación	Hallazgo clave	Limitación
<i>Artificial Intelligence Transcriptomics</i> , 2026	<i>In-in</i> Modelo IURA	Transcriptómica	Transición hacia sistemas autónomos	Marco emergente
<i>BioMedAgent</i> , 2026	Framework multi-agente	Workflows bioinformáticos	Selección autónoma y encadenamiento de tareas	Alto coste computacional
<i>PKGPT</i> , 2026	Agente recursivo basado en LLMs	Modelado farmacocinético	Refinamiento iterativo mediante software externo	Requiere supervisión experta para plausibilidad e interpretabilidad
<i>ChatSpatial</i> , 2026	Orquestación basada en esquemas	Transcriptómica espacial	Reproducibilidad entre workflows R/Python	Preprint; validación todavía emergente

Continúa en la página siguiente

Continuación de la página anterior

Autor, año	Enfoque	Aplicación	Hallazgo clave	Limitación
<i>CellVoyager</i> , 2026	Agente autónomo	Análisis de datos biológicos	Ejecución autónoma de análisis y hallazgos en notebooks	La interpretación final sigue requiriendo revisión experta
<i>Virtual Biotech</i> , 2026	Sistema jerárquico multi-agente	Descubrimiento terapéutico	Orquestación científica de punta a punta	Preprint; evidencia aún preliminar
<i>Benchmarking LLM-based Agents</i> , 2026	Framework de benchmarking	Ómicas de célula única	Evaluación de capacidades agénticas en análisis ómicos	Benchmarks limitados
<i>MCPmed</i> , 2026	Arquitectura basada en MCP	Servicios web bioinformáticos	Interoperabilidad entre agentes y servicios web bioinformáticos	Propuesta temprana
<i>Reliable Data Science Copilots</i> , 2026	Refinamiento iterativo	Programación científica	Necesidad de validación iterativa	Baja precisión inicial sin refinamiento
<i>Metaviral Workflow Generation</i> , 2026	Generación automática de pipelines	Virología computacional	Automatización de workflows multi-step	Riesgo de alucinaciones
<i>ggplotAgent</i> , 2026	Agente auto-correctivo	Visualización científica	Corrección autónoma de errores	Alcance limitado
<i>Functional Genomics Assistant</i> , 2025	Asistente basado en evidencia	Genómica funcional	Mejora trazabilidad y procedencia	Requiere fuentes curadas
<i>Multi-Agent AI Systems Review</i> , 2026	Survey / taxonomía	Datos biológicos y clínicos	Tendencias en arquitecturas multi-agente	Evidencia mayormente teórica

Continúa en la página siguiente

Autor, año	Enfoque	Aplicación	Hallazgo clave	Limitación
<i>AI Agents for Biological Research</i> , 2026	Framework taxonómico 5D	Automatización científica	Clasificación estructurada de sistemas agénticos	Validación experimental limitada
<i>Automated Protein Protocol Optimization</i> , 2026	Automatización basada en LLMs	Protocolos de proteínas	Traducción de literatura a protocolos ejecutables	Desafíos de integración wet-lab

3.1 Arquitecturas agénticas y patrones de orquestación


Trabajos como *BioMedAgent* [2] y *PKGPT* [6] mostraron que es posible integrar herramientas bioinformáticas externas dentro de arquitecturas capaces de ejecutar workflows complejos y refinar sus resultados de manera iterativa, aunque todavía bajo supervisión humana en tareas de alta exigencia técnica. De forma similar, *MCPmed* [7] propuso mecanismos de interoperabilidad entre agentes y servicios web bioinformáticos mediante protocolos estructurados, destacando la necesidad de infraestructuras estandarizadas para sistemas científicos autónomos.

Asimismo, varios estudios identificaron patrones arquitectónicos comunes, incluyendo sistemas jerárquicos multi-agente, agentes recursivos de refinamiento y modelos orientados a la orquestación de tareas científicas complejas.


Es importante precisar que esta caracterización arquitectónica no se basa únicamente en los artículos empíricos incluidos, sino también en una capa teórica de apoyo sobre diseño de agentes, memoria y uso de herramientas. Por ello, aunque los trabajos centrados exclusivamente en *prompting* simple fueron excluidos del corpus principal, el nivel de LLM base se conserva aquí como referencia conceptual para mostrar el salto estructural hacia sistemas con planificación, estado y ejecución externa. En ese puente conceptual, la documentación oficial de LangChain resulta útil para describir de manera estandarizada cómo se articulan los componentes mínimos de un agente moderno, incluyendo el ciclo modelo-herramientas, la memoria operativa y la interacción con funciones externas [3–5].

Esta evolución arquitectónica se puede categorizar en tres estadios (Figure 2). Inicialmente, los sistemas operaban mediante *prompting* directo (Nivel 1). La introducción de frameworks como LangChain permitió el desarrollo de agentes con capacidad de razonamiento y uso de herramientas (Nivel 2), donde el LLM actúa como un motor de decisiones para ejecutar software bioinformático. Finalmente, la frontera actual se desplaza hacia sistemas multi-agente jerárquicos (Nivel 3), donde un supervisor coordina agentes especial-


izados y distribuye subtarefas científicas complejas, como se observa en propuestas recientes como *Virtual Biotech* [8] (*preprint*) y en marcos de interoperabilidad como *MCPmed* [7].



(a) LLM base



(b) Agente con herramientas



(c) Arquitectura agéntica

Figure 2. Evolución conceptual desde modelos LLM usados mediante *prompting* directo hacia agentes con herramientas y arquitecturas agénticas capaces de planificar, ejecutar, validar y refinar workflows científicos.

Recuadro 1 | Concepto clave

Un sistema agéntico combina razonamiento, planificación, memoria operativa, uso de herramientas externas y ciclos de retroalimentación. Esta arquitectura permite que el LLM deje de funcionar como un generador aislado de texto y pase a actuar como coordinador de un workflow computacional verificable.

En bioinformática, esta separación entre razonamiento y ejecución es crítica porque permite delegar tareas técnicas a software especializado mientras se mantiene una capa de supervisión y validación.

Ejemplo de workflow en Python:

```
1 from langchain.llms import OpenAI
2 from langchain.agents import initialize_agent, Tool
```

```

3
4 # Inicializar LLM
5 llm = OpenAI(temperature=0.0, model="gpt-4")
6
7 # Definir herramientas bioinformaticas
8 tools = [
9     Tool(
10         name="PubMedSearch",
11         func=search_pubmed,
12         description="Buscar articulos relevantes en PubMed"
13     ),
14     Tool(
15         name="ParseSequence",
16         func=parse_fasta,
17         description="Procesar archivos de secuencias FASTA"
18     ),
19 ]
20
21 # Crear agente
22 agent = initialize_agent(tools, llm, agent="zero-shot-react-
    description")
23 result = agent.run("Buscar articulos sobre aplicaciones de CRISPR
    ")

```

Listing 1. Workflow en Python con una libreria de LLMs, como LangChain u OpenAI API.

Hallazgo clave del eje 1

La transición desde prompting directo hacia arquitecturas agénticas permite que los LLMs coordinen herramientas externas, ejecuten procesos iterativos y estructuren mejor el workflow científico, aunque la validación humana sigue siendo necesaria en tareas de alta sensibilidad biológica o clínica.

3.2 Automatización de pipelines bioinformáticos específicos

Una parte significativa de los estudios seleccionados se enfocó en la automatización de workflows computacionales en áreas como transcriptómica, *single-cell omics*, modelado farmacocinético y generación automatizada de protocolos experimentales.

Sistemas como *CellVoyager* [9] demostraron la capacidad de los agentes para proponer análisis, ejecutarlos y producir resultados de forma autónoma dentro de notebooks com-

putacionales, especialmente en escenarios de *single-cell omics*. Otros trabajos mostraron la generación automática de pipelines multi-step para virología y workflows de análisis ómicos, reduciendo la intervención manual en tareas repetitivas y de ensamblaje técnico [10].

Además, algunos estudios extendieron estas capacidades hacia entornos wet-lab, traduciendo información contenida en artículos científicos en protocolos experimentales ejecutables.




Figure 3. Representación conceptual de un workflow bioinformático automatizado mediante sistemas agénticos.

Un aspecto crítico en esta automatización es la transición hacia workflows de ciclo cerrado (*closed-loop*). A diferencia de los scripts estáticos, agentes como *CellVoyager* [9] operan en entornos de ejecución dinámica, como Jupyter Notebooks, donde el éxito de una tarea depende de la retroalimentación inmediata del intérprete de código. Esta capacidad de autocorrección amplía el alcance de procesos complejos, como el análisis de *single-cell omics*, y desplaza parte de la carga técnica desde el investigador hacia el sistema, aunque no elimina por completo la necesidad de revisión experta sobre la interpretación final.

Table 3. Comparación de sistemas, herramientas o enfoques evaluados en los estudios.

Sistema	Enfoque	Dominio	Contribución principal
CellVoyager	Agente autónomo	<i>Single-cell omics</i>	Ejecución autónoma de análisis y generación de hallazgos en notebooks.
PKGPT	Agente recursivo	Farmacometría	Refinamiento iterativo de modelos NONMEM mediante ejecución externa y evaluación repetida.
ChatSpatial	Orquestación por esquemas	Transcriptómica espacial	Reproducibilidad de workflows entre entornos R y Python mediante esquemas validados.
Alvessa	Asistente con <i>grounding</i>	Genómica funcional	Verificación a nivel de sentencia y trazabilidad de evidencia.

3.3 Reproducibilidad, benchmarking y evaluación comparativa

La reproducibilidad fue identificada como uno de los principales desafíos asociados al uso de sistemas basados en agentes dentro de bioinformática. Diversos estudios propusieron mecanismos para mejorar la trazabilidad, consistencia y verificabilidad de los workflows automatizados.

ChatSpatial [11] introdujo estrategias de orquestación basadas en esquemas estructurados para mejorar la consistencia entre entornos R y Python, mientras que otros trabajos propusieron asistentes basados en evidencia y mecanismos de *grounding* para reducir alucinaciones y mejorar la procedencia de la información [12].

De igual manera, algunos estudios desarrollaron frameworks de benchmarking orientados a evaluar la calidad de generación de código, la ejecución de tareas analíticas y la robustez de distintas capacidades agénticas en workflows bioinformáticos complejos.

Finalmente, la adopción de herramientas de observabilidad como LangSmith [13, 14] puede ser especialmente útil para fortalecer la robustez de estos sistemas. Estas plataformas permiten una auditoría granular de los grafos de ejecución, facilitando la identificación de cuellos de botella y errores de razonamiento en flujos multi-agente, lo que eleva el estándar de reproducibilidad al permitir que investigadores externos inspeccionen cada paso lógico




Figure 4. Observabilidad de sistemas agénticos para auditoría de trazas, grafos de ejecución y consumo de recursos en workflows automatizados.

y el consumo de recursos de los experimentos automatizados.

3.4 Limitaciones técnicas y consideraciones de gobernanza

A pesar del potencial observado en los sistemas basados en LLMs y agentes, la literatura revisada reportó múltiples limitaciones relacionadas con alucinaciones, coste computacional, dependencia de herramientas externas y problemas de reproducibilidad.

Varios estudios señalaron que los LLMs presentan tasas de error significativas durante ejecuciones iniciales, haciendo necesaria la incorporación de mecanismos de validación iterativa, autocorrección y supervisión humana. Asimismo, el elevado consumo de recursos computacionales y coste asociado al uso continuo de modelos avanzados representa una barrera importante para su adopción generalizada.

Finalmente, diferentes autores enfatizaron la ausencia de estándares claros para la gobernanza y evaluación de sistemas agénticos en entornos científicos, destacando la necesidad de desarrollar marcos normativos, estrategias de supervisión humana y protocolos de validación reproducibles para futuras implementaciones en bioinformática.




Figure 5. La supervisión humana y la observabilidad son componentes críticos del workflow agéntico: permiten intervenir en puntos de validación, auditar decisiones intermedias y mantener el control experimental durante la ejecución de pipelines bioinformáticos automatizados.

Table 4. Limitaciones técnicas y estrategias de mitigación para sistemas agénticos en bioinformática.

Categoría	Limitación técnica	Estrategia de mitigación
Fiabilidad	Alucinaciones en rutas metabólicas o secuencias.	<i>Grounding</i> y verificación a nivel de sentencia (Alvessa 12).
Arquitectura	Errores en cascada en flujos multi-agente.	Implementación de <i>unit testing</i> y observabilidad (LangSmith 13).
Coste	Elevado consumo de tokens en ciclos recursivos.	Uso de modelos <i>small-language</i> (SLMs) para tareas de soporte.
Gobernanza	Falta de trazabilidad en decisiones autónomas.	Protocolos de <i>human-in-the-loop</i> en puntos críticos de validación.
Interoperabilidad	Incompatibilidad entre herramientas biológicas.	Estandarización mediante el <i>Model Context Protocol</i> (MCP 7).

La literatura sugiere que el despliegue de estos sistemas debe estar regido por un marco de gobernanza clínica y técnica. Un desafío crítico es el “coste de la autonomía”; por ejemplo, sistemas que utilizan razonamiento recursivo pueden consumir entre 15 y 50 veces más tokens que un enfoque *zero-shot*. Para mitigar esto, se propone la integración de capas de observabilidad que permitan monitorizar el presupuesto de tokens en tiempo real. Además, la gobernanza debe incluir protocolos de validación humana obligatoria antes de la transición de un flujo computacional (*in silico*) a uno experimental (*in vitro*), asegurando que la IA actúe como un copiloto de alta velocidad y no como un tomador de decisiones final sin supervisión.

4 Discusión

4.1 Hallazgos principales

Los hallazgos de esta revisión subrayan que los sistemas agénticos no son solo una mejora incremental, sino un cambio de paradigma en la bioinformática computacional. Se identificó que la autocorrección iterativa es el componente vital que permite la automatización de tareas que anteriormente requerían supervisión humana constante, como el modelado PopPK o ciertos análisis de *single-cell omics*, aunque la validación experta continúa siendo necesaria en etapas críticas.

Un hallazgo fundamental es el valor de la orquestación jerárquica, donde un agente supervisor coordina a especialistas en herramientas y distribuye tareas analíticas de forma más estructurada. No obstante, los resultados también revelan que la calidad de los prompts de sistema y la estructura de las herramientas disponibles, es decir, herramientas agénticas o legibles por máquina, son determinantes centrales del éxito del workflow.

Este patrón valida la necesidad de protocolos como el *Model Context Protocol* (MCP) para el futuro del área, ya que la interoperabilidad entre agentes, herramientas bioinformáticas y entornos de ejecución científica emerge como una condición central para escalar estos sistemas de forma reproducible.

4.2 Limitaciones

A pesar del potencial disruptivo, la implementación de agentes en bioinformática enfrenta barreras técnicas críticas. El comportamiento no determinista de los modelos subyacentes introduce una variabilidad inaceptable en flujos de trabajo que requieren precisión absoluta, como el modelado PopPK. Asimismo, la propagación de errores en arquitecturas jerárquicas, donde una alucinación inicial contamina las etapas subsiguientes, subraya la inmadurez de los mecanismos de autocorrección actuales.

La literatura también destaca la ausencia de estándares de diseño, lo que genera una fragmentación de herramientas que dificulta la interoperabilidad. Finalmente, la reproducibilidad sigue siendo un desafío abierto; la naturaleza de “caja negra” de los LLMs comerciales impide asegurar que un experimento automatizado produzca resultados idénticos en el tiempo, lo que requiere una transición hacia modelos locales y registros de observabilidad más estrictos.

- **Comportamiento no determinista:** Los LLMs pueden generar respuestas distintas ante el mismo prompt, lo que en bioinformática es crítico. Un agente puede proponer un script de PyMOL funcional hoy y uno con errores de sintaxis mañana. Esto obliga a implementar capas de validación de esquemas, como propone *ChatSpatial*, para forzar una estructura en la salida.
- **Propagación de errores:** En sistemas multi-agente, si el agente investigador extrae un dato erróneo de PubMed, el agente programador escribirá código basado en ese error y el agente analista generará conclusiones falsas. Sin un monitor de errores, como LangSmith [13, 14], este error puede permanecer invisible hasta el final del flujo.
- **Falta de estándares de diseño:** Actualmente no existe un lenguaje universal para que los agentes interactúen con herramientas bioinformáticas. Cada desarrollador crea sus propias funciones de Python. Aquí surge la necesidad del *Model Context Protocol* (MCP) [7] para estandarizar la invocación de herramientas bioinformáticas externas por parte de agentes.
- **Dificultad en la reproducibilidad:** Debido a la actualización constante de modelos comerciales, un workflow agéntico documentado en 2025 podría no funcionar igual en 2026, lo que desafía los principios de la ciencia abierta y dificulta la revisión por pares.

Table 5. Impacto de las principales limitaciones de los sistemas agénticos en bioinformática y estrategias de mitigación sugeridas.

Limitación	Impacto en bioinformática	Mitigación sugerida
No determinismo	Variabilidad en resultados de simulaciones.	Fijación de temperatura ($T = 0$) y <i>prompt engineering</i> robusto.
Propagación	Alucinaciones científicas verosímiles.	Mecanismos de <i>grounding</i> y validación cruzada entre agentes.
Falta de estándares	Fragmentación de herramientas y silos.	Adopción de protocolos de interoperabilidad, como MCPmed 7.
Reproducibilidad	Imposibilidad de replicar pipelines exactos.	Registro exhaustivo de versiones y trazas de ejecución, como LangSmith 13.

4.3 Vacíos en la literatura

La revisión identifica vacíos críticos que limitan la adopción masiva de estas tecnologías. En primer lugar, la falta de benchmarks estandarizados impide una comparación justa entre las crecientes arquitecturas agénticas, relegando la evaluación a éxitos anecdóticos en lugar de métricas universales.

En segundo lugar, existe una carencia de evaluaciones comparativas rigurosas que analicen la relación entre el costo computacional y la ganancia en precisión científica, un factor determinante para la sostenibilidad en el entorno académico. Finalmente, la ausencia de estudios en entornos reales deja abierta la capacidad de estos sistemas para manejar ambigüedad y requisitos de seguridad sobre datos genómicos sensibles.

Cerrar estos vacíos será clave para pasar de prototipos experimentales a sistemas de producción científica confiables.

5 Conclusiones

5.1 El cambio de paradigma: de LLMs a sistemas agénticos

La revisión de la literatura permite concluir que los modelos de lenguaje por sí solos son insuficientes para las demandas de la bioinformática debido a su naturaleza probabilística. Sin embargo, la transición hacia sistemas agénticos, que integran razonamiento, uso de herramientas externas y ciclos de retroalimentación, ha demostrado ser un avance disruptivo.

Estos sistemas no solo “escriben” código, sino que actúan como agentes ejecutores capaces de iterar hasta alcanzar soluciones técnicas válidas, como se observó en la automatización del modelado farmacocinético y en distintos escenarios de análisis de *single-cell omics*, aunque todavía requieren supervisión humana para validar plausibilidad, reproducibilidad e interpretación.

5.2 La verificabilidad como requisito científico

Un hallazgo crítico es que la autonomía no debe comprometer la integridad científica. La implementación de estrategias de *grounding* y verificación a nivel de sentencia, como en el caso de *Alvessa* [12], es esencial para transformar las alucinaciones de los modelos en resultados trazables.

La integración de herramientas de observabilidad como LangSmith [13, 14] se perfila como un apoyo metodológico valioso para fortalecer la auditoría y la reproducibilidad de los descubrimientos científicos generados por IA.

5.3 Perspectivas futuras y estandarización

El futuro de la automatización en bioinformática depende de la creación de un ecosistema interoperable. La adopción de protocolos como el *Model Context Protocol* (MCP) y el desarrollo de benchmarks especializados, como GenomeArena en genómica funcional, serán catalizadores importantes para pasar de prototipos aislados a infraestructuras de investigación robustas.

A medida que se reduzcan los costes computacionales y mejore la precisión de los agentes, estos sistemas se convertirán en colaboradores esenciales en el laboratorio, permitiendo que el investigador humano se desplace de las tareas de ejecución técnica hacia la formulación de hipótesis de alto nivel y la toma de decisiones estratégicas.

En conclusión, los sistemas basados en agentes no solo automatizan tareas repetitivas, sino que democratizan el acceso a flujos de trabajo bioinformáticos complejos, siempre que su despliegue esté regido por marcos de gobernanza transparentes, observabilidad estricta y una validación humana continua.

References

- [1] Artificial intelligence in transcriptomics: From human-in-the-loop to agentic ai. <https://pubmed.ncbi.nlm.nih.gov/42042548/>, 2026. PMID: 42042548.
- [2] Empowering ai data scientists using a multi-agent llm framework with self-evolving capabilities for autonomous, tool-aware biomedical data analyses. <https://pubmed.ncbi.nlm.nih.gov/41912700/>, 2026. PMID: 41912700.
- [3] Agents - docs by langchain. <https://docs.langchain.com/oss/python/langchain/agents>, 2026. Documentación oficial consultada el 7 de mayo de 2026.
- [4] Memory overview - docs by langchain. <https://docs.langchain.com/oss/python/concepts/memory>, 2026. Documentación oficial consultada el 7 de mayo de 2026.
- [5] Tools - docs by langchain. <https://docs.langchain.com/oss/python/langchain/tools>, 2026. Documentación oficial consultada el 7 de mayo de 2026.
- [6] Pkgpt: Expert-orchestrated recursive llm agent for automated nonmem poppk modeling with human benchmarking. <https://pubmed.ncbi.nlm.nih.gov/42076151/>, 2026. PMID: 42076151.
- [7] Mcpmed: a call for model context protocol-enabled bioinformatics web services for llm-driven discovery. <https://pubmed.ncbi.nlm.nih.gov/41729821/>, 2026. PMID: 41729821.
- [8] The virtual biotech: A multi-agent ai framework for therapeutic discovery and development. <https://pubmed.ncbi.nlm.nih.gov/41808990/>, 2026. PMID: 41808990.
- [9] Cellvoyager: Ai compbio agent generates new insights by autonomously analyzing biological data. <https://pubmed.ncbi.nlm.nih.gov/41845065/>, 2026. PMID: 41845065.
- [10] Prompt-based bioinformatic pipeline generation for a multi-step metaviral workflow. <https://pubmed.ncbi.nlm.nih.gov/41523654/>, 2026. PMID: 41523654.
- [11] Chatspatial: Schema-enforced agentic orchestration for reproducible and cross-platform spatial transcriptomics. <https://pubmed.ncbi.nlm.nih.gov/41890081/>, 2026. PMID: 41890081.
- [12] An evidence-grounded research assistant for functional genomics and drug target assessment. <https://pubmed.ncbi.nlm.nih.gov/41502944/>, 2025. PMID: 41502944.

- [13] Langsmith observability - docs by langchain. <https://docs.langchain.com/langsmith/observability>, 2026. Documentación oficial consultada el 7 de mayo de 2026.
- [14] Observability concepts - docs by langchain. <https://docs.langchain.com/langsmith/observability-concepts>, 2026. Documentación oficial consultada el 7 de mayo de 2026.
- [15] Benchmarking llm-based agents for single-cell omics analysis. <https://pubmed.ncbi.nlm.nih.gov/41742311/>, 2026. PMID: 41742311.
- [16] Making large language models reliable data science programming copilots for biomedical research. <https://pubmed.ncbi.nlm.nih.gov/41571796/>, 2026. PMID: 41571796.
- [17] ggplotagent: a self-debugging multi-modal agent for robust and reproducible scientific visualization. <https://pubmed.ncbi.nlm.nih.gov/41542365/>, 2026. PMID: 41542365.
- [18] A review of multi-agent ai systems for biological and clinical data analysis. <https://pubmed.ncbi.nlm.nih.gov/41874150/>, 2026. PMID: 41874150.
- [19] Artificial intelligence agents for biological research: a survey. <https://pubmed.ncbi.nlm.nih.gov/41744224/>, 2026. PMID: 41744224.
- [20] Automated extraction and optimization of protein purification protocols using multi-agent large language models. <https://pubmed.ncbi.nlm.nih.gov/41959417/>, 2026. PMID: 41959417.